



UNIVERSIDADE FEDERAL DO CEARÁ
SEMESTRE 2026.2

HOMEWORK-RELATÓRIO

ESTATÍSTICA PARA ENGENHARIA

Equipe:

Gabriel Sampaio- 580201

João Pedro Alencar- 582416

Leonardo Alves- 580988

Noah Antunes- 582280

Questão 1-

1. Definição da Amostra e Parâmetros

O objetivo desta primeira etapa é extrair a amostra de trabalho específica e validar o ambiente de análise computacional. Utilizou-se a linguagem R para a leitura do conjunto de dados, seleção de 300 observações consecutivas com base nas matrículas da equipe e extração inicial das estatísticas descritivas do sistema de partilha de bicicletas.

Conforme as instruções, o conjunto de dados específico da equipe (*data_group*) foi extraído do arquivo original que contém dados do sistema de compartilhamento de bicicletas. Os parâmetros para a seleção das 300 observações consecutivas foram definidos com base nas matrículas dos integrantes do grupo:

Leonardo Alves Moreira: 580988

Gabriel Sampaio: 580201

Noah Martins: 582280

João Pedro: 582416

O maior número de matrícula identificado foi $M = 582416$. A partir deste valor, o índice da primeira observação foi calculado pela equação $r = 1 + (M \bmod 100)$, resultando em $r = 17$.

O recorte da amostra de 300 observações consecutivas no sistema compreende o período que se inicia na data 2011-01-17 e finaliza em 2011-11-12.

2. Código R Utilizado

O código R empregado para a leitura dos dados e construção do objeto *data_group*, conforme exigido para a elaboração do relatório, é apresentado a seguir:

```
R
dados_originais <- read.csv("HW1_bike_sharing.csv")
matriculas <- c(580988, 580201, 582280, 582416)
M <- max(matriculas)
r <- 1 + (M %% 100)
linha_final <- r + 299
data_group <- dados_originais[r:linha_final, ]
```

3. Cálculos Teóricos e Validação no R (10 Primeiras Observações)

Para a verificação estatística inicial, o método exige a explicitação das fórmulas teóricas para as medidas de tendência central e de dispersão aplicadas ao rol ordenado (

$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$) das 10 primeiras observações da demanda de utilizadores ($n = 10$):

Média: Calculada pelo rácio entre o somatório de todos os alugueis diários e o tamanho

da amostra: $\bar{x} = \frac{\sum_{i=1}^{10} x_i}{10}$.

Mediana: Sendo n par, calcula-se a média aritmética das duas observações centrais do

rol ordenado: $Md = \frac{x_{(5)} + x_{(6)}}{2}$.

Quartis (Q_1 e Q_3): Obtidos mediante o particionamento do conjunto de dados em quatro partes iguais, onde Q_1 delimita os 25% menores valores e Q_3 delimita os 75%.

Mínimo e Máximo: Correspondem aos extremos numéricos do rol ordenado, $x_{(1)}$ e $x_{(10)}$, respetivamente.

A aplicação da função analítica no R validou a correspondência com a metodologia teórica, resultando nas seguintes métricas para a operação do sistema de bicicletas neste recorte inicial:

Mínimo (506.0): Patamar mínimo de utilização diária do sistema.

Primeiro Quartil (982.2): Limite de locações para os 25% dias de pior procura.

Mediana (1208.0): Ponto central exato da procura diária (50% das ocorrências).

Média (1267.7): Volume médio diário de bicicletas partilhadas.

Terceiro Quartil (1623.2): Limite de utilização para 75% dos dias, antecedendo os picos de alta movimentação.

Máximo (1985.0): O volume diário absoluto de locações no período analisado.

Questão 2-

Esta etapa objetiva caracterizar estruturalmente as variáveis do sistema, aferir a presença de valores ausentes e examinar as medidas de tendência central e de dispersão para o volume diário de utilizadores (*total_user*). Os procedimentos envolveram funções nativas do ambiente R para o cálculo estatístico numérico e geração de ferramentas visuais de distribuição (histograma e boxplot), culminando na definição de um limiar matemático para isolar os dias de baixa utilização.

2.1: Valores Ausentes e Classificação das Variáveis

De acordo com o dicionário de dados, as variáveis do sistema dividem-se em categóricas (*season, weathersit*), numéricas (*instant, temp, casual, registered, total_user*) e formato de data (*dteday*). A inspeção do conjunto de dados indicou um total de 0 valores ausentes (NA). Este resultado demonstra a integridade da amostra, indicando que não há falhas na coleta diária dos registros de aluguel durante o período selecionado.

2.2: Medidas de Tendência Central

Para a variável numérica *total_user* (soma de usuários casuais e registrados), calcularam-se as medidas de tendência central. Os resultados indicam:

Média (3599.867): Representa o volume médio diário de bicicletas alugadas no período analisado.

Mediana (4052): Indica que em 50% dos dias observados, a demanda total foi de até 4052 bicicletas.

Moda (1685): Corresponde ao quantitativo específico de usuários diários que ocorreu com maior repetição na amostra.

No contexto operacional, a diferença entre a média e a mediana sugere uma assimetria na distribuição dos aluguéis diários, indicando que dias de demanda muito baixa (como a moda sugere) puxam o valor médio para baixo, afastando-o do ponto central exato (mediana).

2.3: Quartis, Intervalo Interquartil e Valores Atípicos

A dispersão da variável *total_user* foi avaliada por meio de quartis. Observou-se o primeiro quartil (Q_1) em 2359.25, a mediana (Q_2) em 4052 e o terceiro quartil (Q_3) em 4681. O Intervalo Interquartil (IQR), que mede a amplitude dos 50% de dias mais típicos do sistema, foi calculado em 2321.75.


Aplicando o critério do IQR ($Q_1 - 1.5 \times IQR$ e $Q_3 + 1.5 \times IQR$), os limites de normalidade da demanda foram estabelecidos entre -1123.375 e 8163.625. O processamento identificou 0 valores atípicos (outliers). Na prática, a ausência de outliers significa que o sistema de compartilhamento não registrou nenhum dia com picos de demanda ou quedas de utilização severas o suficiente para serem estatisticamente classificados como anômalos.

2.4: Análise Gráfica (Histograma e Boxplot)

A análise visual do histograma e boxplot revela características distintas da distribuição da variável *total_user*.

O histograma evidencia de forma clara uma distribuição bimodal (com dois picos de frequência ao longo do eixo) e assimetria à esquerda. Este comportamento gráfico corrobora os dados do Item 2.2, justificando a média (3599.867) ser inferior à mediana (4052). Este tipo de gráfico foi o mais adequado para revelar a formação de dois grupos distintos de comportamento de demanda.

O boxplot consolida a visualização da dispersão central, destacando o limite imposto pelo IQR (a "caixa" verde). Este gráfico evidencia de forma superior a ausência de valores atípicos, ratificando visualmente que todas as observações estão contidas dentro das hastes (limites de normalidade).



2.5: Dias de Baixa Utilização

Conforme a Equação 1, o primeiro quartil ($Q_1 = 2359.25$) foi adotado como critério de corte para isolar os dias de pior desempenho. A criação da variável binária *low_usage* quantificou 75 dias classificados como de baixa utilização, o que corresponde exatamente a 25% da amostra observada. No contexto de engenharia e gestão do sistema, este limiar isola estatisticamente o quartil inferior de faturamento ou mobilidade, permitindo o direcionamento de estudos futuros para entender quais condições adversas (meteorológicas ou sazonais) deprimem a demanda para abaixo de 2359 bicicletas.

Questão 3-

O objetivo desta etapa é investigar as características ambientais e temporais associadas aos períodos de menor adesão ao sistema de partilha. O método incluiu a aplicação de funções de agregação no R para calcular médias, desvios padrão e a proporção de dias de baixa utilização estratificados por estação do ano e por condição meteorológica. Consecutivamente, aplicou-se o coeficiente de correlação de Pearson e gráficos de dispersão para quantificar a associação linear existente entre a temperatura ambiente e o total de locações diárias.

3.1: Análise da Utilização por Estação do Ano

Para investigar as características associadas aos dias de menor utilização do sistema, avaliou-se a métrica *total_user* agrupada por estação do ano. Os resultados numéricos extraídos demonstram a seguinte variação sazonal na demanda do sistema de compartilhamento:

Primavera: Apresenta os menores índices de demanda (média de 1704.6 e mediana de 1708.0) e a menor variabilidade absoluta (desvio padrão de 589.3). Observou-se que 87.3% dos dias desta estação foram classificados como de baixa utilização (*low_usage*), indicando um período crítico e de ociosidade sistêmica.


Verão: Demonstra uma elevação significativa, com média de 3775.2 e a maior dispersão dos dados (desvio padrão de 1138.9). A proporção de dias de baixa utilização cai para 17.4%.

Outono: Lidera a utilização do sistema, registrando o maior patamar de aluguéis

(média de 4464.4 e mediana de 4615.5). Apenas 3.2% dos dias registraram baixa utilização.

Inverno: Mantém um alto volume de locações (média de 4031.4 e mediana de 4120.0), com a menor taxa de dias de baixa utilização da amostra (2.0%).

O boxplot demonstra visualmente a discrepância da primavera em relação às demais estações. A mediana da primavera encontra-se significativamente inferior, sem sobreposição com as caixas interquartis das outras estações, confirmando a concentração atípica de dados em patamares baixos de locação. O outono apresenta a caixa de dispersão mais elevada, validando a preferência máxima dos usuários neste período.



3.2: Análise da Utilização por Condição Meteorológica

A utilização do sistema também foi quantificada em função das quatro condições meteorológicas categorizadas.

Céu limpo: Corresponde ao cenário ideal e mais frequente (186 dias). Apresenta a maior demanda média (3938.9 usuários), com apenas 17.2% destes dias configurando baixa utilização.


Nublado: Registrou 104 ocorrências na amostra. Apresenta uma redução no volume de usuários (média de 3189.4) e o dobro da taxa de baixa utilização (34.6%) em comparação aos dias de céu limpo.

Chuva fraca: Condição adversa observada em 10 dias. Causa uma queda brusca e severa nos aluguéis, reduzindo a média diária para 1562.4. Nestas condições, 70.0% dos dias foram classificados estatisticamente como de baixa utilização.

Chuva forte: O sistema não registrou a ocorrência de dias com esta classificação na amostra de 300 dias, resultando em valores de média, desvio padrão e proporção ausentes (NA).

A análise gráfica dos boxplots reforça a degradação progressiva da demanda de acordo

com a piora climática. A transição sequencial entre céu limpo, nublado e chuva fraca é acompanhada por uma notável e consistente redução nas respectivas medianas, denotando a sensibilidade do modelo de negócios às intempéries.



3.3: Relação entre Temperatura e Utilização do Sistema

Para investigar a relação entre a temperatura normalizada e a variável *total_user*, calculou-se o coeficiente de correlação de Pearson, obtendo-se o valor de 0.771.

Este valor indica uma associação linear positiva e de intensidade forte. No contexto operacional do sistema, evidencia-se que o aumento da temperatura está diretamente associado à elevação no volume diário de locação de bicicletas.

Como limitação intrínseca da métrica, o coeficiente de Pearson mensura estritamente associações lineares e não comprova causalidade exclusiva, visto que a temperatura possui interações naturais com outras variáveis exógenas simultâneas (como a estação do ano e a precipitação) que afetam o comportamento final do usuário.

3.4: Seleção de Características Associadas

Com base nos resultados estatísticos e gráficos elaborados, selecionaram-se as duas características que evidenciam maior associação com a variação na utilização do sistema: a Estação do Ano e a Condição Meteorológica.


A escolha justifica-se pela variabilidade extrema detectada na proporção de dias de baixa utilização em ambas as variáveis. Observou-se que a sazonalidade altera a ociosidade do sistema de 87.3% (primavera) para apenas 2.0% (inverno). De maneira análoga, a degradação climática eleva a taxa de dias de baixa utilização de 17.2% (céu limpo) para 70.0% (chuva fraca), demonstrando forte impacto e vulnerabilidade operacional a estas duas condições.

Questão 4-

A etapa final propõe a síntese temporal da operação do sistema e o aprofundamento das características de impacto previamente identificadas. A metodologia consistiu na construção de uma série temporal no R para evidenciar as flutuações e tendências da procura ao longo do ano. Para fundamentar as hipóteses visuais, executou-se o teste estatístico de Análise de Variância (ANOVA), a fim de atestar o grau de significância da associação entre as categorias sazonais/climáticas e a quantidade de utilizadores. Por fim, estratificou-se a correlação da temperatura de acordo com os níveis de desempenho do sistema.

4.1: Série Temporal de Utilização

A construção da série temporal ilustrada permitiu a visualização da evolução diária da variável *total_user*. Os dados indicam que o dia de menor utilização na amostra ocorreu em 2011-01-27, registrando apenas 431 locações, situado em um período inicial caracterizado por vales de demanda. Em contrapartida, o pico absoluto de utilização foi identificado no dia 2011-07-04, atingindo 6043 usuários. O comportamento gráfico revela uma clara tendência de crescimento no volume de alugueis em direção aos meses centrais do ano, característicos do verão no hemisfério norte, acompanhada de expressiva volatilidade e oscilações bruscas diárias.



4.2: Associação Estatística das Características

Para aprofundar a avaliação das características de impacto no sistema, aplicou-se a Análise de Variância (ANOVA) com o objetivo de testar formalmente a associação das variáveis categóricas com o volume total de usuários.

Estação do Ano: O teste estatístico resultou em um valor F de 124.2 e um p-valor inferior a $2e-16$ (***). Este resultado indica que as diferenças nas médias de locação

observadas entre as quatro estações são estatisticamente significativas, confirmando a sazonalidade da operação.

Condição Meteorológica: A avaliação resultou em um valor F de 25.21 e um p-valor de 7.72×10^{-11} (***). Este indicador atesta que as variações climáticas afetam de maneira significativa o comportamento da demanda, comprovando que as quedas abruptas de utilização em dias nublados e chuvosos não decorrem de flutuações aleatórias do sistema.

4.3: Relação entre Temperatura e Utilização Estratificada

A relação entre a temperatura normalizada e o total de alugueis foi analisada de forma estratificada, utilizando a variável binária *low_usage* para separar o comportamento do sistema.

Para os dias de baixa utilização (1º quartil), o coeficiente de correlação linear calculado foi de 0.252, revelando uma associação fraca. Para os demais dias (operação normal a alta), a correlação subiu para 0.466. No contexto prático de compartilhamento de bicicletas, este distanciamento indica que, em dias com desempenho severamente degradado (condições que forcem a baixa utilização, como chuvas intensas), variações incrementais na temperatura exercem pouca influência na decisão do usuário. Contudo, em dias de operação normal, a temperatura atua como um impulsionador mais forte e direto para o aumento dos alugueis.

4.4: Conclusão Final

Com base nos resultados consolidados, conclui-se que o sistema de compartilhamento de bicicletas apresenta uma demanda altamente elástica e dependente de fatores ambientais e temporais. Os testes estatísticos indicam que a "Estação do Ano" e as "Condições Meteorológicas" são os parâmetros de maior associação com o volume de alugueis, validados pela Análise de Variância (p-valores próximos a zero). O sistema atinge sua capacidade ociosa em dias de chuva e durante a primavera (com 87.3% e 70.0% de seus dias classificados como baixa utilização, respectivamente), derrubando a mediana de operações. A temperatura comprovou-se como um fator linear de fomento à demanda (correlação de 0.771 no escopo geral), embora perca sua força tratora em dias atípicos de baixo fluxo. Para a engenharia de operações, os dados sugerem a otimização de frotas, indicando que períodos adversos de clima e temperatura devem ser preferidos para a execução de manutenções preventivas, garantindo disponibilidade máxima para os picos de verão e outono.